



دانشگاه صنعتی اصفهان

دانشکده مهندسی برق و کامپیوتر

شناسایی مراحل حمله‌ی تهدید پایدار پیشرفته با استفاده از جنگل تصادفی

پر دیس غیبی

استاد درس

دکتر مازیار پالهنک

۱۴۰۳

در گذشته، تلاش بر کاهش جرایم سایبری (بدافزار، هرزنامه و تلاش‌های دسترسی غیرمجاز) متمرکز بود. این رویکرد دفاعی اغلب بر این فرض استوار است که مهاجمان در صورت مواجهه با اقدامات امنیتی قوی به دنبال اهداف آسان‌تری خواهند بود. با این حال، طبق گزارش تکنیکی ارائه شده توسط ترند میکرو [۱] تغییر قابل توجه‌ای را در چشم انداز تهدیدهای سایبری برجسته می‌کند. افزایش حمله‌های هدفمند یا تهدیدهای پایدار پیشرفته^۱ نشان دهنده انحراف از رویکرد سابق جرایم سایبری است. در تهدید پایدار پیشرفته، مهاجمان بسیار ماهر، با دقت سازمان‌های خاصی را انتخاب می‌کنند. اغلب سازمان‌هایی که در بخش‌های حیاتی مانند دولتی، دفاعی یا مالی فعالیت می‌کنند هدف این دسته از حمله‌ها هستند. مهاجمان تهدیدهای پایدار پیشرفته در تلاش هستند به شبکه‌های سازمان هدف نفوذ کنند و گاهی برای رسیدن به اهداف خود ماه‌ها یا حتی سال‌ها در شبکه‌ی هدف مستقر می‌مانند.

تهدیدهای پایدار پیشرفته، نوعی حمله چندمرحله‌ای است که با پنهان‌کاری بیشتر اجرا می‌شود و به طور خاص برای دستیابی به یک هدف معین، اغلب جاسوسی، هدف‌گذاری می‌شود. این حمله‌ها همانند حمله‌های چندمرحله‌ای رایج از مراحل مختلفی برای رسیدن به هدف خود استفاده می‌کنند. شناسایی به‌موقع این تهدیدها به دلیل کاهش تأثیر آن‌ها و حفاظت از دارایی‌های سازمانی امری حیاتی است. از رویکردهای مختلفی برای شناسایی تهدید پایدار پیشرفته می‌توان استفاده کرد از جمله رویکردهای سنتی مانند سیستم‌های تشخیص نفوذ مبتنی بر امضا^۲ تا رویکردهای پیشرفته از جمله روش‌های مبتنی بر یادگیری ماشین و تحلیل‌های رفتاری سیستم. اسکنرهای ویروس^۳، فایروال‌ها^۴ و سیستم‌های تشخیص نفوذ مبتنی بر ناهنجاری^۵ باهدف کاهش خسارات اقتصادی ناشی از جرایم سایبری ایجاد شدند. در این پژوهش، تلاش شده است با معرفی راهکاری مبتنی بر جنگل تصادفی روشی جهت شناسایی این حمله‌ها بیان شود.

۱-۲ مجموعه داده

مجموعه داده‌های مرتبط با تهدیدهای پایدار پیشرفته از اهمیت بالایی برخوردارند، چرا که به محققان و متخصصان امنیت سایبری در توسعه ابزارها و روش‌های نوین برای شناسایی و مقابله با این تهدیدات یاری می‌رسانند. مجموعه داده‌های مرتبط با تهدیدهای پایدار پیشرفته شامل مجموعه داده‌های واقعی، مصنوعی و نیمه مصنوعی است. با این وجود، دسترسی به مجموعه داده‌های واقعی و عمومی مربوط به این تهدیدها به دلیل ماهیت پنهان این حمله‌ها، دشواری تجزیه و تحلیل داده‌ها و ملاحظات امنیتی و حفظ حریم خصوصی سازمان‌های هدف، محدود است. از این رو، بیشتر مجموعه داده‌های عمومی که برای ارزیابی پژوهش‌های شناسایی تهدیدهای پایدار پیشرفته استفاده می‌شوند، مجموعه داده‌های ارائه شده برای دستگاه‌های تشخیص نفوذ است.

¹ Advanced Persistent Threats (APT)

² Signature-based IDS

³ Virus Scanner

⁴ Firewall

⁵ Anomaly-based IDS

مجموعه داده [۲] DAPT 2020 به طور خاص برای مقابله با چالش‌های شناسایی و مدل‌سازی تهدیدهای پایدار پیشرفته طراحی شده است که با پیچیدگی و مخفی بودن شناخته می‌شوند. این مجموعه داده که از طریق شبیه‌سازی رفتارهای تهدیدهای پایدار پیشرفته در یک دوره پنج روزه در یک شبکه ابری ایجاد شده است، شامل ترافیک عادی و حمله می‌باشد، مراحل مختلف تهدیدهای پایدار پیشرفته مانند شناسایی، استقرار پایگاه، حرکت جانبی و استخراج داده‌ها را ثبت می‌کند. برخلاف مجموعه داده‌های نفوذی سنتی، DAPT 2020 منعکس کننده ظرافت حمله‌های تهدید پایدار پیشرفته با الگوهای ترافیکی پیچیده است که تشخیص آن از رفتار عادی چالش برانگیز است. این به مسائل عدم تعادل طبقاتی که اغلب در مجموعه داده‌های حملات سایبری یافت می‌شود می‌پردازد و به عنوان معیاری برای توسعه مدل‌های یادگیری ماشینی با قابلیت شناسایی تهدیدهای پیچیده عمل می‌کند. به طور کلی، DAPT 2020 نمایشی واقعی از رفتارهای تهدیدهای پایدار پیشرفته ارائه می‌دهد.

۳-۱ رویکرد پیشنهادی

مجموعه داده‌ی مورد استفاده شامل داده‌های پنج روز است. ابتدا، به ترکیب این داده‌ها و پیش‌پردازش آن‌ها پرداخته شده است. در این بخش، همانطور که در شکل ۱-۱ مشخص است، داده‌های گم‌شده و مقدارهای بی‌نهایت و خالی بررسی شده‌اند. طبق نتایج، داده‌های روز پنجم در بخش نام‌گذاری ویژگی‌ها متفاوت بود که ابتدا به یکسان سازی آن‌ها پرداخته شد.

```

1 #Data loading and organization
2 monday_pub = '/csv/enp83-monday-pcap_flow.csv'
3 monday_pv = '/csv/enp83-monday-pvt-pcap_flow.csv'
4 tuesday_pub = '/csv/enp83-public-tuesday-pcap_flow.csv'
5 tuesday_pv = '/csv/enp83-pvt-tuesday-pcap_flow.csv'
6 wednesday_pub = '/csv/enp83-public-wednesday-pcap_flow.csv'
7 wednesday_pv = '/csv/enp83-pvt-wednesday-pcap_flow.csv'
8 thursday_pub = '/csv/enp83-public-thursday-pcap_flow.csv'
9 thursday_pv = '/csv/enp83-pvt-thursday-pcap_flow.csv'
10 friday_pub = '/csv/enp83-tcpdump-friday-pcap_flow.csv'
11 friday_pv = '/csv/enp83-tcpdump-pvt-friday-pcap_flow.csv'
12
13 mon_pub = pd.read_csv(monday_pub, header=0)
14 mon_pv = pd.read_csv(monday_pv, header=0)
15 tue_pub = pd.read_csv(tuesday_pub, header=0)
16 tue_pv = pd.read_csv(tuesday_pv, header=0)
17 wed_pub = pd.read_csv(wednesday_pub, header=0)
18 wed_pv = pd.read_csv(wednesday_pv, header=0)
19 thu_pub = pd.read_csv(thursday_pub, header=0)
20 thu_pv = pd.read_csv(thursday_pv, header=0)
21 fri_pub = pd.read_csv(friday_pub, header=0)
22 fri_pv = pd.read_csv(friday_pv, header=0)
23
24 #Correcting columns for dataframe "thu_pv"
25 thu_pv.columns = ['Flow ID', 'Src IP', 'Src Port', 'Dst IP', 'Dst Port', 'Protocol',
26                  'Timestamp', 'Flow Duration', 'Total Fwd Packet', 'Total Bwd packets',
27                  'Total Length of Fwd Packet', 'Total Length of Bwd Packet',
28                  'Fwd Packet Length Max', 'Fwd Packet Length Min',
29                  'Fwd Packet Length Mean', 'Fwd Packet Length Std',
30                  'Bwd Packet Length Max', 'Bwd Packet Length Min',
31                  'Bwd Packet Length Mean', 'Bwd Packet Length Std', 'Flow Bytes/s',
32                  'Flow Packets/s', 'Flow IAT Mean', 'Flow IAT Std', 'Flow IAT Max',
33                  'Flow IAT Min', 'Fwd IAT Total', 'Fwd IAT Mean', 'Fwd IAT Std',
34                  'Fwd IAT Max', 'Fwd IAT Min', 'Bwd IAT Total', 'Bwd IAT Mean',
35                  'Bwd IAT Std', 'Bwd IAT Max', 'Bwd IAT Min', 'Fwd PSH Flags',
36                  'Bwd PSH Flags', 'Fwd URG Flags', 'Bwd URG Flags', 'Fwd Header Length',
37                  'Bwd Header Length', 'Fwd Packets/s', 'Bwd Packets/s',
38                  'Packet Length Min', 'Packet Length Max', 'Packet Length Mean',
39                  'Packet Length Std', 'Packet Length Variance', 'FIN Flag Count',
40                  'SYN Flag Count', 'RST Flag Count', 'PSH Flag Count', 'ACK Flag Count',
41                  'URG Flag Count', 'CWR Flag Count', 'ECE Flag Count', 'Down/Up Ratio',
42                  'Average Packet Size', 'Fwd Segment Size Avg', 'Bwd Segment Size Avg',
43                  'Fwd Bytes/Bulk Avg', 'Fwd Packet/Bulk Avg', 'Fwd Bulk Rate Avg',
44                  'Bwd Bytes/Bulk Avg', 'Bwd Packet/Bulk Avg', 'Bwd Bulk Rate Avg',
45                  'Subflow Fwd Packets', 'Subflow Fwd Bytes', 'Subflow Bwd Packets',
46                  'Subflow Bwd Bytes', 'Fwd Init Min Bytes', 'Bwd Init Min Bytes',
47                  'Fwd Act Data Pkts', 'Fwd Sng Size Min', 'Active Mean', 'Active Std',
48                  'Active Max', 'Active Min', 'Idle Mean', 'Idle Std', 'Idle Max',
49                  'Idle Min', 'Activity', 'Stage']
50 dfs = [mon_pub, mon_pv, tue_pub, tue_pv, wed_pub, wed_pv, thu_pub, thu_pv, fri_pub, fri_pv]

```

شکل ۱-۱ یکسان‌سازی عنوان ویژگی‌ها

در ادامه، به شناسایی مقادارهای گم شده^۱ و ویژگی‌های غیر عددی پرداخته شد و مقادارهای غیر عددی تبدیل به مقادارهای عددی شدند. این مراحل در شکل ۲-۱ مشخص شده است.

```
1 #Data Cleaning
2 #Checking for missing values in the entire DataFrame
3 print(dapt.isnull().any().any())
4
5 #changing categorical columns to numerical
6 categorical_columns = ['Src IP', 'Dst IP', 'Flow ID']
7
8 #Method1: Using Sparse Matrices
9 encoder = OneHotEncoder(sparse_output=True)
10 # encoded_features = encoder.fit_transform(dapt[['Src IP', 'Dst IP', 'Flow ID']])
11 # encoded_df = pd.DataFrame.sparse.from_spmatrix(encoded_features)
12 # dapt_encoded = pd.concat([dapt.drop(['Src IP', 'Dst IP', 'Flow ID'], axis=1), encoded_df], axis=1)
13 # print(dapt_encoded.head())
14
15 #Method 2: using OrdinalEncoder from sklearn to avoid one-hot encoding
16 encoder = OrdinalEncoder()
17 encoded_features = encoder.fit_transform(dapt[['Src IP', 'Dst IP', 'Flow ID']])
18 encoded_df = pd.DataFrame(encoded_features, columns=['Src IP', 'Dst IP', 'Flow ID'])
19
20 dapt[['Src IP', 'Dst IP', 'Flow ID']] = encoded_df
21
22 #Converting Timestamp into datetime format to use it for temporal information
24 dapt['Timestamp'] = pd.to_datetime(dapt['Timestamp'], format='%d/%m/%Y %I:%M:%S %p')
```

شکل ۲-۱ پیش پردازش اولیه داده‌ها

سپس عمل برچسب گذاری روی داده‌ها مطابق شکل ۳-۱ انجام شده است. در این بخش، با توجه به مقدار ویژگی Stage که بیانگر مرحله‌ی حمله یا داده‌ی خوش خیم است برچسب گذاری انجام شده است.

```
1 unique_stages = dapt['Stage'].unique()
2 # for stage_label in unique_stages:
3 #     print("Stages:\t" + stage_label)
4
5 unique_activity = dapt['Activity'].unique()
6 # for activity_label in unique_activity:
7 #     print("Activity:\t" + activity_label)
8
9 class_mapping = {
10     'Benign': 0,
11     'BENIGN': 0,
12     'Reconnaissance': 1,
13     'Establish Foothold': 2,
14     'Lateral Movement': 3,
15     'Data Exfiltration': 4
16 }
17
18 class_counts = dapt['Stage'].value_counts()
19 dapt['Label'] = dapt['Stage'].map(class_mapping)
20
```

شکل ۳-۱ برچسب گذاری داده‌ها

¹ Missing Values

در نهایت، در بخش اولیه‌ی پیش‌پردازش داده‌ها، مقدارهای جایگزین برای مقدار بی‌نهایت و null انتخاب شده‌اند. در این پژوهش مقدار بی‌نهایت، با دو برابر بیشترین مقدار برای آن ویژگی جایگزین می‌شود. همچنین مقدارهای خالی نیز با صفر جایگزین شده‌اند که این مراحل در شکل ۴-۱ مشخص شده است.

```

1 replaceInfinity = 1
2 replaceNaN = 0
3 nColumns = len(X[0])
4
5 if replaceInfinity == "1":
6     print("Replacing Infinity with the max value of the feature and nan with " + str(replaceNaN) + ".")
7     strippedDataset = []
8     for i in range(len(X)):
9         if 'nan' not in X[i] and 'Infinity' not in X[i]:
10             strippedDataset.append(X[i])
11     strippedDataset = np.array(strippedDataset)
12
13     maxValues = []
14     stringColumns = []
15     infinityColumns = []
16
17     for j in range(nColumns):
18         try:
19             maxValue = np.amax(X[:, j])
20             if maxValue == 'Infinity':
21                 maxValue = float(np.amax(strippedDataset[:, j])) * 2
22             maxValue = float(maxValue)
23         except:
24             maxValue = 0
25         stringColumns.append(j)
26         maxValues.append(maxValue)
27
28     for i in range(len(X)):
29         for j in range(nColumns):
30             if str.lower(str(X[i, j])) == 'infinity':
31                 X[i, j] = float(maxValues[j])
32             elif str.lower(str(X[i, j])) == 'nan':
33                 X[i, j] = replaceNaN
34     else:
35         print("\n\nReplacing Infinity and nan with " + str(replaceInfinity) + ", " + str(replaceNaN) + ".")
36     for i in range(len(X)):
37         for j in range(nColumns):
38             if str.lower(str(X[i, j])) == 'infinity':
39                 X[i, j] = replaceInfinity
40             elif str.lower(str(X[i, j])) == 'nan':
41                 X[i, j] = replaceNaN
42
43 print("Creating cleaned file.")
44 fileCleaned = "dapt_data.csv"
45 column_headers = dapt.columns.tolist()
46 np.savetxt(fileCleaned, np.array(X), delimiter=',', fmt="%s", header=",".join(column_headers), comments='')
47 print("Cleaned file " + fileCleaned + " has been created.")

```

شکل ۴-۱ جایگزینی مقادیر بی‌نهایت و خالی

پس از این مرحله، از مجموعه داده‌ی بدست آمده، ویژگی‌های فعالیت، زمان رویداد و مرحله‌ی حمله مطابق شکل ۵-۱ حذف می‌شوند. زیرا فعالیت و مرحله‌ی حمله ویژگی‌هایی هستند که با استفاده از آن‌ها برجسب‌ها ساخته شده است. علاوه بر این، چون در این پروژه زنجیره‌ی حمله بازسازی نمی‌شود، از ویژگی زمان حمله نیز صرف نظر شده است. می‌توان از ویژگی‌های دیگری مانند آدرس‌های مورد استفاده در شبکه نیز چشم‌پوشی کرد ولی در این پژوهش که در راستای کمک به تیم امنیتی سازمان‌ها در جهت شناسایی حمله است، این آدرس‌ها در شناسایی آدرس‌های مخرب و سیستم‌های تحت نفوذ مهاجم کارایی دارد و از آن‌ها استفاده شده است.

```

1 # Prepare Features and Labels
2 X = dapt.drop(['Timestamp', 'Label', 'Stage', 'Activity'], axis=1)
3 y = dapt['Label']
4
5 # Normalize Features
6 scaler = MinMaxScaler()
7 X = pd.DataFrame(scaler.fit_transform(X), columns=X.columns)
8
9 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

```

شکل ۵-۱ آماده‌سازی مجموعه داده جهت آموزش مدل

در ادامه جهت بررسی پارامترهای مناسب مدل، از مجموعه‌ای از پارامترهای مختلف استفاده شده است و با بررسی رویکرد هر کدام، پارامترهای بهینه انتخاب می‌شوند. همانطور که در شکل ۶-۱ مشخص شده است. مدل استفاده شده در این پژوهش جنگل تصادفی است که در پژوهش‌های مختلف و دسته‌بندی‌های چنددسته‌ای موفق عمل کرده است.

```
1 # Train Random Forest Classifier
2 max_depth_values = [5, 10, 15, 20]
3 n_estimators_values = [50, 75, 100, 150]
4
5 # max_depth_values = [15]
6 # n_estimators_values = [50]
7
8 results = {'max_depth': [], 'n_estimators': [], 'train_accuracy': [], 'test_accuracy': []}
9 metrics = {'max_depth': [], 'n_estimators': [], 'accuracy': [], 'precision': [], 'recall': [], 'f1_score': []}
10
11 kf = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
12 cv_results = []
13
14 confusion_matrices = {}
15
16 # Loop through combinations of max_depth and n_estimators
17 for max_depth in max_depth_values:
18     for n_estimators in n_estimators_values:
19         rf = RandomForestClassifier(
20             n_estimators=n_estimators,
21             max_depth=max_depth,
22             random_state=42
23         )
24         rf.fit(X_train, y_train)
25
26         train_acc = rf.score(X_train, y_train)
27         test_acc = rf.score(X_test, y_test)
28
29         y_pred = rf.predict(X_test)
30         cm = confusion_matrix(y_test, y_pred)
31
32         scores = cross_val_score(rf, X, y, cv=kf, scoring='accuracy')
33         cv_results.append({
34             'max_depth': max_depth,
35             'n_estimators': n_estimators,
36             'mean_accuracy': scores.mean(),
37             'std_accuracy': scores.std()
38         })
39
40 TP, TN, FP, FN, acc, prec, rec, f1 = calculate_metrics(cm)
41 confusion_matrices[(max_depth, n_estimators)] = cm
42
43 results['max_depth'].append(max_depth)
44 results['n_estimators'].append(n_estimators)
45 results['train_accuracy'].append(train_acc)
46 results['test_accuracy'].append(test_acc)
```

شکل ۶-۱ آموزش و آزمون مدل جنگل تصادفی

۴-۱ نتایج و ارزیابی

معیارهای ارزیابی که به صورت معمول در سیستم‌های تشخیص نفوذ استفاده می‌شوند شامل کارایی سیستم در تشخیص حمله و زمان تشخیص ناهنجاری است. جهت ارزیابی کارایی سیستم در تشخیص حمله، چهار میزان مثبت صحیح^۱، مثبت کاذب^۲، منفی

^۱ True Positive (TP)

^۲ False Positive (FP)

صحيح^۱ و منفي كاذب^۲ محاسبه مي گردد. در ادامه به توضيح اين تعاريف و معيارهاي ارزيابي كه در اين پژوهش استفاده شده است، پرداخته خواهد شد.

- **مثبت صحيح**

درصد تشخيص صحيح يا مثبت صحيح، توانايي سيستم را در تشخيص صحيح حمله ها نشان مي دهد. هرچقدر اين معيار بيشتر باشد به اين معناست كه سيستم تشخيص در شناسايي حمله ها موفق عمل كرده است.

- **مثبت كاذب**

درصد تشخيص نادرست حمله، مربوط به زماني است كه حمله اتفاق نيفتاده است؛ ولي سيستم تشخيص رخداد يك حمله را نشان مي دهد.

- **منفي صحيح**

درصد تشخيص صحيح عدم حمله يا منفي صحيح، مربوط به زماني است كه حمله اتفاق نيفتاده است و سيستم تشخيص نيز هشداري مبتني بر رخداد حمله نشان نمي دهد. هرچقدر درصد اين معيار بيشتر باشد، بيانگر سربار كمتر سيستم تشخيص است.

- **منفي كاذب**

درصد عدم تشخيص حمله ي واقعي، بيانگر وقوع حمله است؛ ولي سيستم تشخيص هشداري مبتني بر رخداد حمله نشان نمي دهد. هرچقدر درصد اين معيار بيشتر باشد، نشان دهنده ي ناكامي سيستم تشخيص در شناسايي حمله ها است.

- **دقت**

دقت^۳، بيانگر ميزان هشدارهاي صحيح سيستم تشخيص نسبت به تمام هشدارهاي آن است. اين معيار درستي عملکرد مدل را در سناريوهاي مختلف نشان مي دهد. اين معيار از رابطه ي زير به دست مي آيد:

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \quad (1-1)$$

- **صحت**

¹ True Negative (TN)

² False Negative (FN)

³ Accuracy

صحت^۱، نشان‌دهنده‌ی این امر است که سیستم تشخیص تا چه میزان قادر است از مثبت کاذب جلوگیری کند. این معیار میزان دقت در تشخیص را مشخص می‌کند که شامل میزان هشدار صحیح به کل هشدارهای تولید شده است. در این معیار هرچقدر میزان مثبت کاذب کمتر باشد، دقت سیستم تشخیص بیشتر خواهد بود. این معیار از رابطه‌ی زیر به دست می‌آید:

$$Precision = \frac{TP}{TP+FP} \quad (۲-۱)$$

• حساسیت

حساسیت^۲ یا بازخوانی، بیانگر دقت مدل در تشخیص حمله‌های واقعی است. در این معیار هرچقدر میزان منفی کاذب کمتر باشد، دقت مدل بیشتر است. این معیار از رابطه‌ی زیر به دست می‌آید:

$$Recall = \frac{TP}{TP+FN} \quad (۳-۱)$$

• F-Score

این معیار میانگین هارمونیک^۳ بین $Precision$ و $Recall$ را نشان می‌دهد و از رابطه‌ی زیر به دست می‌آید:

$$F - Score = 2 \times \frac{Recall \times Precision}{Recall + Precision} \quad (۴-۱)$$

• ماتریس درهم‌ریختگی

در مسائل طبقه‌بندی یک مجموعه داده، هدف الگوریتم یادگیری ماشین دستیابی به بیشترین دقت و صحت ممکن در تشخیص و طبقه‌بندی کلاس‌ها است. در برخی مسائل طبقه‌بندی و تشخیص صحیح یک کلاس اهمیت بیشتری دارد. در مواقعی که شناسایی یک کلاس اهمیت بیشتری دارد از مفهوم ماتریس درهم‌ریختگی استفاده می‌شود. جدول ۱-۱ ماتریس درهم‌ریختگی و نحوه‌ی محاسبه‌ی درایه‌های آن را نشان می‌دهد.

جدول ۱-۱ ماتریس درهم‌ریختگی

		برچسب پیش‌بینی شده	
		مثبت	منفی
برچسب واقعی	مثبت	مثبت صحیح	منفی کاذب
	منفی	مثبت کاذب	منفی صحیح

^۱ Precision

^۲ Recall

^۳ Harmonic Mean

• اعتبارسنجی متقابل



اعتبارسنجی متقابل^۱، یک روش ارزیابی مدل‌های یادگیری ماشین است که تعیین می‌نماید نتایج یک تحلیل آماری بر روی یک مجموعه داده تا چه اندازه قابل تعمیم و مستقل از داده‌های آموزشی است. در اعتبارسنجی متقابل، تکیه بر داده‌هایی است که مشاهده شده‌اند؛ ولی در هنگام ساختن مدل به کار گرفته نمی‌شوند. این داده‌ها به منظور بررسی و سنجش کارایی مدل برای پیش‌بینی داده‌های جدید به کار می‌روند.

نتایج دقت آموزش و آزمون مدل، در شکل ۷-۱ قابل مشاهده است. همانطور که مشخص است، در عمق ۲۰ دقت آموزش به ۱۰۰ درصد می‌رسد و دقت آزمون نیز ۹۹ درصد می‌باشد. به دلیل اختلاف کم این دو مقدار، متوجه هستیم که دچار بیش برازش نشده‌ایم ولی می‌توان نتایج نزدیکی را با عمق کمتر بدست آورد که از نظر زمانی، بهینه‌تر است.




در شکل ۸-۱ نتایج ماتریس درهم‌ریختگی را برای مقادیر مختلف پارامترها قابل مشاهده است. همانطور که مشاهده می‌شود، عمق ۱۵ و تعداد تخمین زن ۵۰ الی ۷۵ مقداری نزدیک به عمق ۲۰ دارد که می‌توان با کاهش عمق، به پاسخی که نزدیک به بهینه است برسیم.

علاوه بر این، نتایج اعتبارسنجی متقابل برای مقدار ۵ و میانگین دقت آن‌ها در شکل ۹-۱ قابل مشاهده است. همانطور که در نتایج مشخص است، عمق ۱۵ و تعداد تخمین زن ۵۰ الی ۷۵ دقت قابل توجهی را ارائه می‌دهد.


¹ Cross-validation



شکل ۷-۱ نتایج دقت آموزش و آزمون مدل با مقادیر پارامترهای مختلف



شکل ۸-۱ نتایج ماتریس درهم‌ریختگی به ازای مقادیر مختلف عمق و تخمین‌زن‌ها



شکل ۹-۱ نتایج اعتبارسنجی متقابل

در جدول ۱-۲ نتایج معیارهای ارزیابی دقت، صحت، حساسیت و F-score برای پارامترهای عمق‌های ۱۵ و ۲۰ و همچنین تعداد تخمین‌زن‌های ۵۰ و ۷۵ قابل مشاهده است. همانطور که مشخص شده است، جنگل تصادفی با عمق ۱۵ و تعداد تخمین‌زن ۷۵، نتایج حساسیت و F-score بهتری نسبت به عمق ۲۰ داشته است.

جدول ۲-۱ نتایج معیارهای ارزیابی برای عمق‌های ۱۵ و ۲۰ و تعداد تخمین‌زن‌های ۵۰ و ۷۵

دقت	صحت	حساسیت	F-score	
۰.۹۹۷۱	۰.۹۸۶۷	۰.۸۸۱۴	۰.۹۳۱۱	عمق ۱۵ - تخمین‌زن ۵۰
۰.۹۹۷۳	۰.۹۸۸۷	۰.۸۸۲۰	۰.۹۳۲۳	عمق ۱۵ - تخمین‌زن ۷۵
۰.۹۹۷۳	۰.۹۹۱۴	۰.۸۷۹۵	۰.۹۳۲۱	عمق ۲۰ - تخمین‌زن ۵۰
۰.۹۹۷۵	۰.۹۹۱۴	۰.۸۸۱۱	۰.۹۳۳۰	عمق ۲۰ - تخمین‌زن ۷۵

۵-۱ نتیجه‌گیری

تهدیدهای پایدار پیشرفته نوعی از حمله‌های سایبری پیچیده و پنهان هستند که توسط مهاجمان ماهر برای نفوذ به شبکه‌ها و سرقت اطلاعات حساس صورت می‌پذیرند. ماهیت مخفیانه‌ی این حمله‌ها، شناسایی و مقابله با آن‌ها را با دشواری‌هایی مواجه می‌کند. روش‌های سنتی تشخیص این تهدیدها اغلب کارآمدی کافی را ندارند، زیرا تهدیدهای پایدار پیشرفته از ترکیبی از تکنیک‌های مختلف برای نفوذ به شبکه‌ها استفاده می‌کنند (دارای ماهیت ترکیبی هستند)، می‌توانند برای مدت طولانی در شبکه پنهان بمانند (دارای ماهیت بلندمدت هستند) و می‌توانند از چندین نقطه‌ی مختلف به شبکه حمله کنند (دارای ماهیت توزیع پذیر هستند). این پژوهش باهدف ارائه‌ی رویکردی مبتنی بر جنگل تصادفی برای شناسایی دقیق و کارآمد تهدیدهای پایدار پیشرفته نگاشته شده است.

این رویکرد در سه مرحله‌ی پیش‌پردازش داده‌ها، مدلسازی و انتخاب پارامترهای بهینه صورت گرفت. در ادامه، رویکرد با استفاده از مجموعه‌داده‌ی DAPT مورد ارزیابی قرار گرفت. با توجه به نتایج ارزیابی، این رویکرد قادر به شناسایی تهدیدهای پایدار پیشرفته با دقت ۹۹ درصد و حساسیت ۸۸ درصد می‌باشد.

۶-۱ کارهای آتی

درحالی‌که رویکرد پیشنهادی در این پژوهش، دستاورد قابل‌توجهی در شناسایی تهدیدهای پایدار پیشرفته به دست آورده است، اما زمینه‌ی امنیت سایبری، حوزه‌ای پویاست که همواره نیازمند پیشرفت و توسعه‌ی بیشتر است. این بخش، مسیرهای بالقوه‌ای را برای تحقیقات پیشرو در زمینه‌ی شناسایی این تهدیدها پیشنهاد می‌کند.

در این پژوهش، به شناسایی هر مرحله از تهدید پایدار پیشرفته پرداخته شد. پیشنهاد می‌شود که در کارهای آتی، به شناسایی زنجیره‌ی تهدید پایدار پیشرفته و ارتباط میان مراحل مختلف حمله پرداخته شود.

منابع

- [١] "Targeted attacks and how to defend against them," T M technical report, 2017. Accessed: Feb. 2021. [Online]. Available: <http://www.trendmicro.co.uk/media/misc/targeted-attacks-and-how-to-defend-against-them-en.pdf>
- [٢] S. Myneni *et al.*, "DAPT 2020-constructing a benchmark dataset for advanced persistent threats," in *Deployable Machine Learning for Security Defense: First International Workshop, MLHat 2020, San Diego, CA, USA, August 24, 2020, Proceedings 1*, 2020: Springer, pp. 138-163 .